API Ceris IA

Observabilidade do grafo de agentes · Mongo para a página, LangSmith para a seção 04

`application="ia"` `Período: 26 out 2026 – 02 nov 2026`

Resumo do período

26 out 2026 – 02 nov 2026 · 245 execuções · mesma base dos gráficos e do relatório

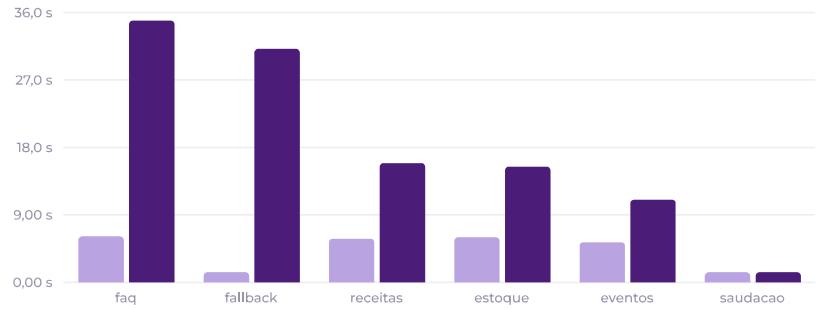
245	21,5 s	US$ 0,21	31,43%	7,14%
Execuções	p95 E2E	Custo total	Taxa de erro	Devoluções do juiz

01 Performance

Latência por rota, decomposição por nó e leitura de nota

Latência E2E por rota

segundos · p50 e p95 em séries distintas



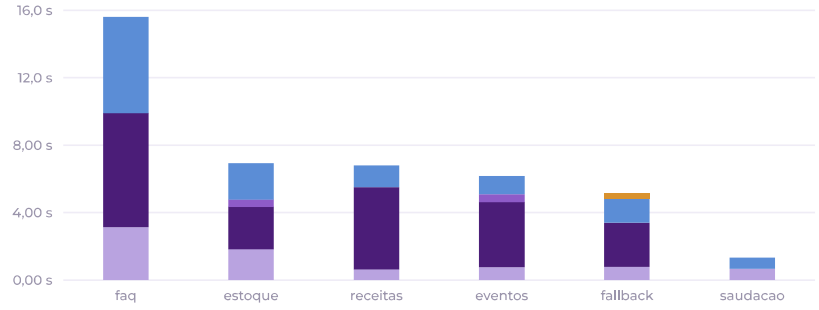
p50 p95

Volume por rota: faq 3 · fallback 82 · receitas 119 · estoque 24 · eventos 16 · saudacao 1

`metrics · duration_ms por rota`

Latência média por nó · empilhada

segundos · contribuição de cada etapa por rota



Roteador Agente Juiz Guardrails Orquestrador

`Soma das etapas = média E2E da rota, não soma de percentis`

Leitura de nota

Unidades separadas · 30 leituras no período

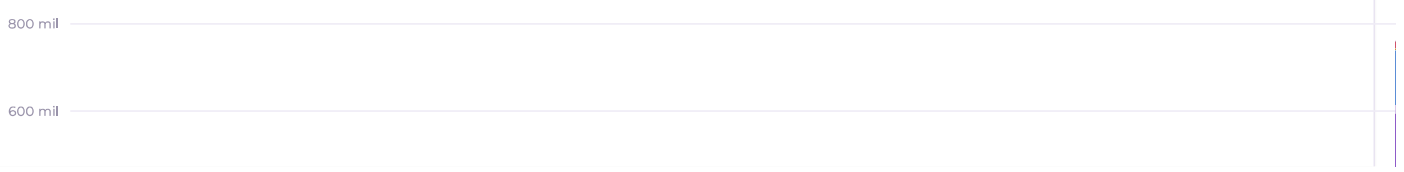
30	96,8 s	237,3 s	86,67%
Leituras · contagem	Tempo médio por leitura	p95 por leitura	Sucesso · 26 de 30

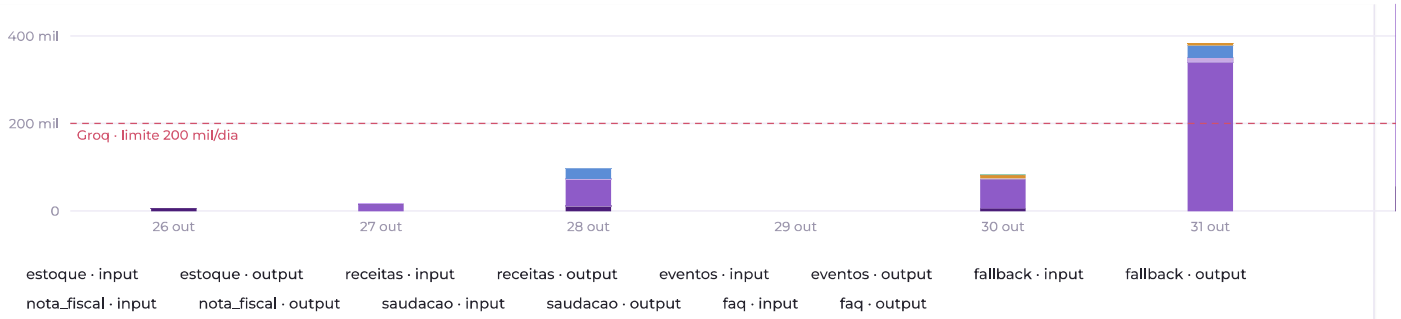
02 Custo e capacidade

Tokens por dia e rota, custo por modelo e limites do Groq

Tokens de entrada + saída por dia e rota

mil tokens · 1,88 mi no período · 1,82 mi input + 57,68 mil output

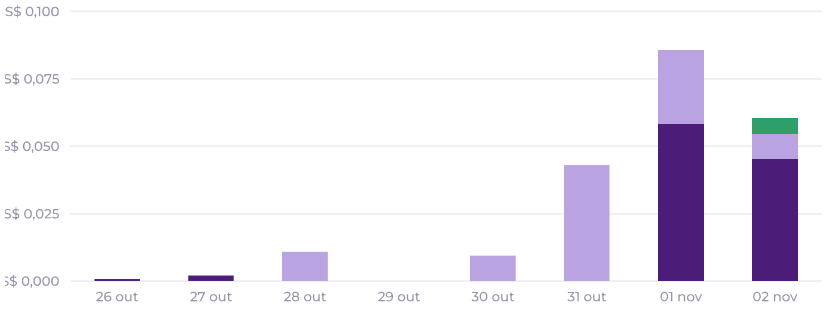




Pico: 01 nov · 760,17 mil · 380,08% do limite

Custo diário por modelo

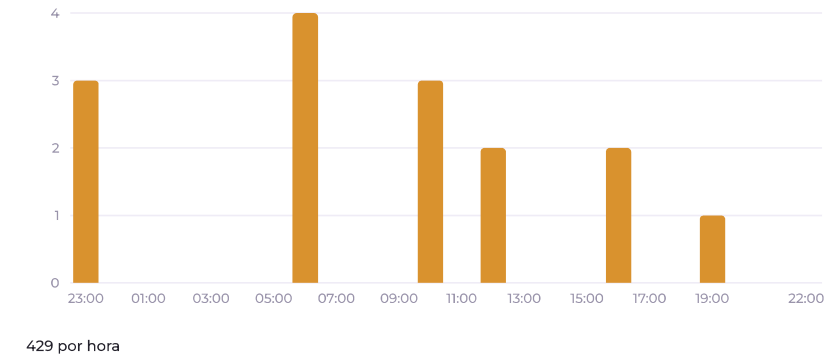
USD · total US$ 0,21 · preços estimados



gemini-3.5-flash-lite US$ 0,11 · gpt-6-luna US$ 0,10 · openai/gpt-oss-20b US$ 0,01

Groq 429 · erros por hora

últimas 24 h · total 15 · período 66



Conta o 429 que chegou ao fim da requisição. O que o retry absorveu vira latência.

03 Qualidade e ferramentas

Decisões do juiz, bloqueios de guardrails e confiabilidade das tools

Decisões do juiz

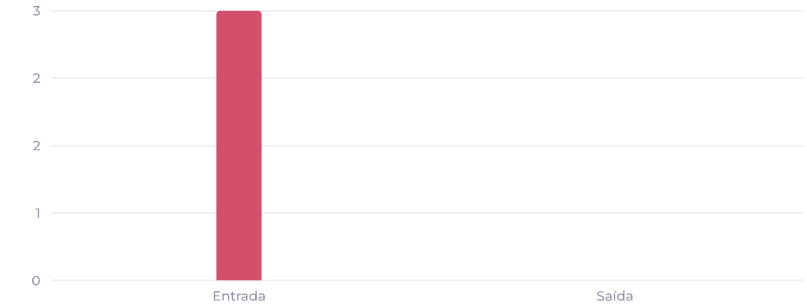
42 decisões · uma por leitura do juiz



39 (93%) aprovadas · 3 (7%) devolvidas · 0 (0%) revertidas pela segunda opinião

Bloqueios de guardrails

contagem por estágio · 3 bloqueios no período



Bloqueios

1,22% de 245 execuções; não são erros de tool

Ferramentas · chamadas, erros e duração média

Mesmos nomes do relatório

Tool	Chamadas	Erros	Taxa de erro	Média (ms)	p95 (ms)
get_stock	131	0	0,00%	59	199
ingredientes_para_comprar	66	0	0,00%	5	9
resolver_data	16	0	0,00%	3	8
get_events	16	0	0,00%	340	1.000
adiar_operacao	9	2	22,22%	3	13
salvar_receita	8	0	0,00%	63	151
get_expired_products	7	0	0,00%	385	1.599
faq_retriever	3	0	0,00%	1.282	1.931
create_event	2	0	0,00%	141	150
buscar_receitas_usuario	2	0	0,00%	968	986
get_list	2	0	0,00%	540	933
create_list	1	0	0,00%	143	143
calcular_percentual	1	0	0,00%	13	13
escalar_quantidades	1	0	0,00%	3	3
buscar_historico	1	0	0,00%	454	454

04 LangSmith

Execuções e erros por dia, percentis por chain e por agente

Consultando o LangSmith... a API é paginada e pode levar alguns segundos.

05 Relatório do período

Resumo visível · período atual contra o anterior de mesmo tamanho

Relatório · API Ceris IA

Atual 26 out 2026 – 02 nov 2026 contra 19 out 2026 – 26 out 2026 · gerado às 22:37

Imprimir

Indicador	Atual	Anterior	Variação
Volume total	245	117	+109,40%
Latência p95 E2E	21,5 s	69,9 s	-69,21%
Custo total	US$ 0,21	US$ 0,14	+46,74%
Taxa de erro	31,43%	19,66%	+11,77 p.p.
Devoluções do juiz	7,14%	6,45%	+0,69 p.p.

Top 3 rotas mais lentas · p95

1. faq · 34,9 s
2. fallback · 31,2 s
3. receitas · 15,9 s

Top 3 tools com maior taxa de erro

1. `adiar_operacao` · 22,22% (2/9)

Consumo: 1,88 mi tokens (1,82 mi input + 57,68 mil output). Pico diário 760,17 mil em 01 nov de 200 mil. Leitura de nota: 30 leituras, 86,67% de sucesso. Juiz: 42 decisões.